

Auditoria Automática de Trabalhos Acadêmicos: Verificação de Alinhamento entre Promessas e Entregas com Uso do DoCO

João Pedro Tentis¹, Pedro Mion Braga¹

¹PESC – Universidade Federal do Rio de Janeiro (UFRJ)

1. Introdução

A produção científica cresce em ritmo acelerado, e com ela surge uma questão que raramente é colocada de forma explícita: artigos científicos cumprem o que prometem? A introdução de um trabalho acadêmico tipicamente estabelece um conjunto de expectativas, lacunas que serão preenchidas, hipóteses que serão testadas, contribuições que serão entregues. Mas a relação entre essas promessas e o que de fato aparece nas seções de resultados e conclusões nem sempre é direta.

Esse descompasso pode ter origens diversas. Em alguns casos, os resultados obtidos simplesmente não correspondem ao que foi antecipado, e o texto é ajustado para minimizar a distância. Em outros, o escopo do trabalho muda ao longo do processo, mas a introdução permanece inalterada. Há ainda situações em que as conclusões extrapolam o que os dados efetivamente sustentam. Independentemente da causa, identificar esse tipo de inconsistência de forma sistemática é um problema não trivial.

O presente trabalho propõe um sistema de *auditoria automática de trabalhos acadêmicos*, baseado na *Document Components Ontology* (DoCO) [Constantin et al. 2016]. A ideia central é simples: se for possível identificar automaticamente quais trechos de um documento representam as promessas feitas na introdução e quais representam os resultados e conclusões entregues, então é possível comparar essas duas partes e gerar um indicador de consistência interna do trabalho.

A proposta se insere no contexto da disciplina de Busca e Mineração de Texto, combinando classificação de texto, representações vetoriais distribuídas e análise de similaridade semântica. Além do interesse metodológico, o trabalho tem motivação prática: em um cenário onde a confiabilidade da literatura científica é cada vez mais discutida, dispor de mecanismos automatizados de verificação de consistência pode ser uma ferramenta valiosa tanto para revisores quanto para leitores em geral.

2. Referencial Teórico e Trabalhos Correlatos

Esta seção apresenta os fundamentos teóricos que sustentam a proposta e posiciona o trabalho em relação ao estado da arte. O projeto se situa na interseção de três áreas: estruturação semântica de documentos, classificação de texto e análise de similaridade.

2.1. Document Components Ontology (DoCO)

O DoCO é um vocabulário estruturado desenvolvido para rotular as partes constituintes de um documento científico [Constantin et al. 2016]. Em conjunto com a *Discourse Elements Ontology* (DEO), o DoCO permite classificar trechos de texto com rótulos funcionais como *Introduction*, *Motivation*, *Methods*, *Results*, *RelatedWork*

e *Conclusion*. Essa granularidade semântica torna o DoCO especialmente adequado para tarefas que dependem da compreensão da função retórica de cada parte do documento, em vez de sua posição estrutural.

2.2. Classificação de Zonas Retóricas

A tarefa de identificar a função retórica de trechos em artigos científicos é estudada na literatura sob o nome de *rhetorical zone classification* ou *argumentative zoning*. Teufel e Moens [Teufel and Moens 2002] propuseram um dos esquemas pioneiros nessa direção, focado em artigos de computação. Trabalhos subsequentes exploraram o uso de *features* linguísticas e estruturais para classificar sentenças em categorias funcionais, abrindo espaço para abordagens baseadas em aprendizado de máquina [Liakata et al. 2010].

Mais recentemente, modelos de linguagem baseados em transformadores, como o SciBERT [Beltagy et al. 2019], mostraram resultados expressivos nessas tarefas ao capturar representações contextuais ricas de texto científico.

2.3. Análise de Similaridade Semântica

A verificação de alinhamento entre promessa e entrega é tratada aqui como um problema de similaridade semântica entre trechos de texto. A representação de texto como vetores densos em espaços de alta dimensão, os *embeddings*, é uma abordagem consolidada para essa finalidade. Modelos como Word2Vec [Mikolov et al. 2013] e GloVe [Pennington et al. 2014] aprendem representações distribuídas a partir de coocorrências lexicais, enquanto modelos baseados em atenção, como o BERT [Devlin et al. 2019], produzem representações contextuais que tendem a capturar melhor nuances semânticas.

A métrica de similaridade do cosseno é amplamente utilizada para comparar vetores de documentos e sentenças [Mikolov et al. 2013], e será adotada neste trabalho como principal indicador de alinhamento entre os segmentos classificados.

2.4. Posicionamento da Proposta

Apesar da vasta literatura sobre classificação de texto científico e análise de similaridade, poucos trabalhos combinam explicitamente o DoCO como esquema de anotação com a tarefa de verificação de consistência interna de documentos.

3. Proposta

O objetivo do trabalho é desenvolver um sistema de auditoria automática capaz de, dado um documento acadêmico em PDF, produzir um indicador de consistência entre as promessas feitas na introdução e as entregas apresentadas nos resultados e conclusões. Toda a documentação técnica, o código-fonte e o desenvolvimento deste artigo podem ser acompanhados através do projeto no **Overleaf** (<https://tinyurl.com/56nx8f4c>) e do repositório no **GitHub** (<https://github.com/jtentis/projeto-BMT>).

O sistema é organizado em três etapas lógicas: Extração e Segmentação do Texto, Classificação com o DoCO e Verificação de Alinhamento.

4. Avaliação

A avaliação do sistema ocorre em dois níveis distintos: Avaliação do classificador (métricas de precisão, revocação e F1-score) e Avaliação do indicador de alinhamento (qualitativa e comparativa).

5. Plano de Execução e Cronograma

O desenvolvimento do projeto está dividido em cinco fases: Levantamento do corpus, Anotação manual/treinamento, Implementação do alinhamento, Avaliação e Escrita final.

6. Conclusão

Este trabalho propõe uma abordagem prática para verificar se trabalhos acadêmicos cumprem o que prometem. A maior incerteza do projeto está na qualidade do classificador DoCO para documentos em português, visto que os recursos disponíveis são majoritariamente em inglês.

References

- [Beltagy et al. 2019] Beltagy, I., Lo, K., and Cohan, A. (2019). Scibert: A pretrained language model for scientific text. *arXiv preprint arXiv:1903.10676*.
- [Constantin et al. 2016] Constantin, A., Peroni, S., Pettifer, S., Shotton, D., and Vitali, F. (2016). The document components ontology (doco). In *Semantic Web*, volume 7, pages 167–181. IOS Press.
- [Devlin et al. 2019] Devlin, J., Chang, M.-W., Lee, K., and Toutanova, K. (2019). Bert: Pre-training of deep bidirectional transformers for language understanding. *arXiv preprint arXiv:1810.04805*.
- [Liakata et al. 2010] Liakata, M., Teufel, S., Sidner, C., et al. (2010). Corpora and the evaluation of automatic labeling of scientific articles. In *Proceedings of LREC*.
- [Mikolov et al. 2013] Mikolov, T., Sutskever, I., Chen, K., Corrado, G. S., and Dean, J. (2013). Distributed representations of words and phrases and their compositionality. In *Advances in neural information processing systems*, pages 3111–3119.
- [Pennington et al. 2014] Pennington, J., Socher, R., and Manning, C. D. (2014). Glove: Global vectors for word representation. In *Proceedings of the 2014 conference on empirical methods in natural language processing (EMNLP)*, pages 1532–1543.
- [Teufel and Moens 2002] Teufel, S. and Moens, M. (2002). Summarizing scientific articles: experiments with relevance and rhetorical status. *Computational linguistics*, 28(4):409–445.