

Dataset Consolidado, Métricas e Protocolo Experimental

João Pedro Tentis¹

¹PESC – Universidade Federal do Rio de Janeiro (UFRJ)

1. Links obrigatórios

- GitHub: <https://github.com/jtentis/projeto-BMT>
- Overleaf: <https://tinyurl.com/56nx8f4c>

2. Objetivo da entrega

Esta entrega consolida o conjunto de dados final, formaliza as métricas e define o desenho experimental utilizado para avaliar o *baseline* atual do projeto BMT. O objetivo principal é reduzir ambiguidades antes da evolução para modelos mais complexos, mantendo uma avaliação simples, *offline* e reproduzível.

O *baseline* avaliado compara a seção de promessa do documento, representada por *introduction*, com as seções de entrega disponíveis, representadas por *results* e *conclusion*. A comparação utiliza vetorização TF-IDF e similaridade do cosseno.

3. Dataset final consolidado

O *dataset* final é composto por 10 trabalhos acadêmicos em PDF, coletados a partir do repositório Pantheon/UFRJ e versionados no repositório do projeto. Os arquivos oficiais de entrada encontram-se em `data/raw/`.

3.1. Origem e coleta

Os documentos foram selecionados entre trabalhos acadêmicos da área de computação, com ênfase em temas associados a desenvolvimento de software, jogos digitais, inteligência artificial e sistemas interativos. A coleta foi realizada manualmente e os arquivos foram armazenados no repositório para garantir a reprodutibilidade local.

3.2. Critérios de inclusão e exclusão

Foram incluídos PDFs acadêmicos completos, com texto extraível pela biblioteca `pypdf`, relacionados ao domínio geral de computação. Foram excluídos arquivos duplicados, documentos sem texto extraível e arquivos fora do formato de trabalho acadêmico (como apresentações ou resumos simples).

3.3. Limpeza e normalização

O *pipeline* executa a extração textual com `pypdf`, reparo heurístico de codificação quando necessário, remoção de hifenização artificial, normalização de espaços e remoção de acentos para a busca de cabeçalhos. Os textos bruto e normalizado são preservados em `reports/baseline/extracted_text/`.

Estatística	Valor
Documentos no corpus	10
Documentos processados sem erro	10
Erros de processamento	0
Páginas totais	706
Caracteres normalizados	972.163
Documentos com introdução detectada	10
Documentos com resultados/entrega detectados	10
Documentos com conclusão detectada	10

Table 1. Estatísticas do dataset consolidado.

Documento	Status
AMDavid	ok
ENPinho	ok
FMRolim	ok
GGSouza	ok
HBCReis	ok
HBMHenriques	ok
LCMarques	ok
LMFGaleno	ok
MDFonseca	ok
PVMNascimento	ok

Table 2. Documentos do corpus final.

3.4. Estatísticas descritivas

4. Divisão de dados e controle de vazamento

O protocolo desta entrega utiliza o *corpus* completo como conjunto fixo de avaliação. Não há divisão em treino, validação e teste, pois o *baseline* atual não treina um modelo supervisionado, não utiliza rótulos manuais e não ajusta parâmetros a partir dos resultados esperados.

O risco de vazamento (*data leakage*) é controlado pelo próprio desenho experimental. O TF-IDF é ajustado somente nos dois trechos comparados dentro de cada documento, sem transferência de vocabulário, pesos ou estatísticas entre diferentes arquivos. Além disso, não há ajuste de limiares por desempenho observado, visto que os limiares de rotulagem são fixos e documentados no código.

A validação cruzada (*cross-validation*) não foi aplicada devido ao tamanho reduzido do *corpus* e ao fato de a etapa atual não envolver aprendizado de máquina. O foco reside em validar se o *pipeline* processa o *dataset* de forma estável.

5. Definição formal das métricas

As métricas de alinhamento calculadas por documento são:

- `tfidf_cosine_similarity`: similaridade do cosseno entre vetores TF-IDF;
- `best_introduction_to_delivery_score`: maior pontuação entre `introduction vs results` e `introduction vs conclusion`;
- `alignment_label`: rótulo discreto derivado do *score* final.

Os limiares utilizados são: `high` ($\text{score} \geq 0.35$), `medium` ($0.15 \leq \text{score} < 0.35$), `low` ($\text{score} < 0.15$) e `insufficient_sections` quando não há seções suficientes para comparação.

Métricas como `Precision@k`, `Recall@k`, `MAP` e `NDCG`, bem como métricas de classificação (`F1-score`, acurácia), exigem anotações manuais ou rótulos esperados (*ground truth*). Como esta entrega não inclui rotulagem manual, tais métricas são definidas como trabalho futuro.

6. Protocolo experimental

O experimento consiste em uma rodada determinística sobre os 10 PDFs consolidados. Não foram utilizadas sementes aleatórias, pois o *pipeline* atual baseia-se em regras heurísticas e similaridade TF-IDF sem amostragem estocástica.

O comando oficial de reprodução é:

```
python -m src.run_baseline --input_dir
data/raw --output_dir reports/baseline
```

Os principais artefatos gerados são:

- `reports/baseline/dataset/summary.json`
- `reports/baseline/protocol/experimental_protocol.json`
- `reports/baseline/alignment/results.json`
- `reports/baseline/metrics.csv`
- `reports/baseline/metrics/coverage_metrics.json`

7. Análise de riscos de validade

O principal risco à validade interna reside na segmentação heurística. Como a detecção depende de padrões textuais extraídos do PDF, eventuais erros na estrutura editorial podem deslocar os limites das seções.

Quanto à validade externa, o tamanho do *corpus* (10 documentos) permite validar o desenho experimental, mas não sustenta generalizações amplas sobre toda a produção acadêmica da área.

Há também o risco de validade de construto: a similaridade TF-IDF mede sobreposição lexical e pode não capturar alinhamento semântico profundo. Portanto, os resultados devem ser interpretados como um *baseline* inicial.

8. Resultados do baseline recalculado

Table 3: Resultados recalculados do baseline no dataset consolidado.

Documento	Status	Promessa	Entrega	Score	Rótulo
AMDavid	ok	introduction	results;conclusion	0.4040	high
ENPinho	ok	introduction	results;conclusion	0.3280	medium
FMRolim	ok	introduction	results;conclusion	0.5123	high
GGSouza	ok	introduction	results;conclusion	0.4525	high
HBCReis	ok	introduction	results;conclusion	0.4680	high
HBMHenriques	ok	introduction	results;conclusion	0.3190	medium
LCMarques	ok	introduction	results;conclusion	0.0000	low
LMFGaleno	ok	introduction	results;conclusion	0.6510	high
MDFonseca	ok	introduction	results;conclusion	0.4065	high
PVMNascimento	ok	introduction	results;conclusion	0.4224	high

A distribuição dos rótulos totalizou 7 documentos com alinhamento `high`, 2 documentos com alinhamento `medium`, 1 documento com alinhamento `low` e nenhum documento com `insufficient_sections`. Todos os 10 documentos foram passíveis de avaliação.

9. Conclusão

A entrega consolida o *dataset* final, formaliza o protocolo experimental e recalcula o *baseline* de forma reproduzível. Os resultados indicam que o *pipeline* atual processa todos os documentos do *corpus* e produz métricas consistentes, reforçando a viabilidade da transição para modelos mais robustos e métricas supervisionadas nas próximas etapas.