

Relatório Intermediário: Evolução do Baseline e Análise Crítica

João Pedro Tentis¹

¹PESC – Universidade Federal do Rio de Janeiro (UFRJ)

1. Links obrigatórios

- GitHub: <https://github.com/jtentis/projeto-BMT>
- Overleaf: <https://tinyurl.com/56nx8f4c>

2. Objetivo da entrega

Esta entrega intermediária apresenta a evolução do projeto após a definição do *baseline* inicial. O foco não é substituir o *baseline* por um modelo supervisionado neste momento, mas mostrar progresso substancial na estabilização experimental: consolidação do *dataset*, formalização do protocolo, definição de métricas, recálculo dos resultados e análise crítica das limitações observadas.

O problema continua sendo a auditoria automática de trabalhos acadêmicos, buscando verificar o alinhamento entre promessas feitas na introdução e entregas presentes em resultados ou conclusão. A abordagem atual permanece simples e reproduzível, usando segmentação heurística, vetorização TF-IDF e similaridade do cosseno.

3. Estado anterior do baseline

Na entrega de *baseline*, o sistema já executava um fluxo completo de leitura de PDFs, extração textual, normalização, segmentação por cabeçalhos numerados e comparação entre seções. A principal contribuição daquela etapa foi transformar a proposta em um *pipeline* executável, com artefatos em `reports/baseline/`.

Entretanto, o desenho experimental ainda era limitado. O corpus usado como referência era pequeno, a documentação das decisões de avaliação ainda não estava consolidada e as métricas estavam concentradas no score por documento. Assim, o *baseline* servia como prova inicial de viabilidade, mas ainda não oferecia uma base suficientemente organizada para comparação futura com modelos mais fortes.

4. Evoluções implementadas

A evolução principal foi a consolidação do corpus final em `data/raw/`, com 10 trabalhos acadêmicos em PDF. Todos os documentos foram processados sem erro, gerando textos extraídos, textos normalizados, segmentações por documento, métricas por documento e métricas agregadas.

Também foram adicionados artefatos experimentais mais explícitos. O arquivo `reports/baseline/dataset/summary.json` descreve o conjunto de dados, origem, critérios de inclusão e exclusão, normalização e estatísticas. O arquivo `reports/baseline/protocol/experimental_protocol.json` registra o protocolo experimental, incluindo a justificativa para avaliação descritiva sobre corpus

fixo. Já `reports/baseline/metrics/coverage_metrics.json` resume a cobertura do *pipeline*.

Além disso, foram criados documentos auxiliares em Markdown para tornar o experimento mais auditável: `experimental_protocol.md` e `formal_metrics.md`. Esses arquivos tornam explícito o que está sendo medido, o que ainda não pode ser medido e quais decisões precisam ser revistas em etapas futuras.

5. Decisões técnicas

A primeira decisão técnica foi manter o *baseline* simples e determinístico. Como ainda não há anotação manual de trechos ou rótulos esperados, evoluir diretamente para um classificador supervisionado poderia criar uma falsa sensação de rigor. Por isso, a etapa intermediária priorizou a organização do experimento.

A segunda decisão foi tratar o corpus completo como conjunto fixo de avaliação. Não há divisão entre treino, validação e teste porque o método atual não aprende parâmetros a partir de rótulos. O TF-IDF é ajustado apenas nos trechos comparados dentro de cada documento, sem reutilizar vocabulário, pesos ou estatísticas entre documentos.

A terceira decisão foi preservar métricas simples, mas tornar seus limites claros. O score principal é a similaridade do cosseno entre a introdução e as seções de entrega. O rótulo `high`, `medium` ou `low` é apenas uma interpretação heurística do score, não um julgamento definitivo sobre a qualidade do trabalho acadêmico.

6. Resultados comparativos

A Tabela 1 resume a evolução entre a entrega de *baseline* e o estado intermediário atual.

Aspecto	Baseline inicial	Estado intermediário
Corpus	reduzido e exploratório	10 PDFs consolidados
Protocolo	implícito	documentado em JSON e Markdown
Métricas	score por documento	score, cobertura e distribuição
Artefatos	resultados básicos	dataset, protocolo e métricas agregadas
Avaliação	prova de viabilidade	avaliação descritiva reproduzível

Table 1. Comparação entre o baseline inicial e o estado intermediário.

Na execução atual, os 10 documentos foram processados e avaliados. Não houve erro de extração, e as seções de introdução, entrega e conclusão foram detectadas em todos os documentos. A distribuição dos rótulos foi de 7 documentos classificados como `high`, 2 como `medium` e 1 como `low`.

Table 2: Resultados atuais do baseline no corpus consolidado.

Documento	Status	Promessa	Entrega	Score	Rótulo
AMDavid	ok	introduction	results;conclusion	0.4040	high
ENPinho	ok	introduction	results;conclusion	0.3280	medium
FMRolim	ok	introduction	results;conclusion	0.5123	high
GGSouza	ok	introduction	results;conclusion	0.4525	high
HBCReis	ok	introduction	results;conclusion	0.4680	high
HBMHenriques	ok	introduction	results;conclusion	0.3190	medium
LCMarques	ok	introduction	results;conclusion	0.0000	low
LMFGaleno	ok	introduction	results;conclusion	0.6510	high
MDFonseca	ok	introduction	results;conclusion	0.4065	high
PVMNascimento	ok	introduction	results;conclusion	0.4224	high

O caso mais crítico é *LCMarques*, com score 0.0000. Esse resultado não deve ser interpretado automaticamente como ausência real de alinhamento entre promessa e entrega. Ele também pode indicar falha de segmentação, delimitação inadequada das seções, ruído de extração ou baixa sobreposição lexical entre trechos semanticamente relacionados.

7. Análise crítica de erros e limitações

A principal limitação técnica continua sendo a segmentação heurística. O método depende de cabeçalhos numerados e de padrões textuais relativamente simples. Quando um PDF possui estrutura editorial diferente, sumário ruidoso, codificação problemática ou títulos pouco convencionais, o trecho selecionado pode ficar amplo demais, curto demais ou semanticamente distante da seção desejada.

Outra limitação importante está na métrica de similaridade. TF-IDF com cosseno é útil como referência inicial porque é simples, rápido e reproduzível, mas mede principalmente sobreposição lexical. Dois trechos podem tratar da mesma promessa com vocabulários diferentes e receber score baixo. Da mesma forma, dois trechos podem compartilhar termos frequentes e receber score alto mesmo sem relação argumentativa forte.

Também não há, nesta etapa, anotação manual que permita calcular métricas supervisionadas ou de recuperação de informação. Sem *ground truth*, não é adequado reportar F1, accuracy, MAP, NDCG ou Precision@k como se fossem evidências de qualidade do modelo. A ausência dessas métricas não é uma falha operacional, mas uma restrição metodológica assumida.

Por fim, o corpus ainda é pequeno. Dez documentos são suficientes para validar a reprodução e encontrar limitações concretas do *pipeline*, mas não bastam para generalizar conclusões sobre trabalhos acadêmicos em geral.

8. Próximos passos

O próximo passo mais importante é auditar manualmente uma amostra dos trechos segmentados. Essa auditoria deve verificar se a introdução, os resultados e a conclusão se-

lecionados correspondem às seções corretas do PDF. O caso LCMarques deve receber prioridade, pois o score zero sugere um erro informativo para melhoria do método.

Depois disso, será necessário criar rótulos de referência para permitir avaliação supervisionada. Com esses rótulos, o projeto poderá medir acurácia, F1, macro-F1 e outras métricas compatíveis com a tarefa. Para a dimensão de busca e ranking, será preciso definir julgamentos de relevância antes de calcular Precision@k, Recall@k, MAP ou NDCG.

Também é recomendável comparar o *baseline* atual com representações semânticas mais robustas, como embeddings de sentenças, SciBERT ou modelos da família *sentence-transformers*. Essa comparação deve ser feita apenas depois de estabilizar os rótulos e o protocolo, para evitar que a complexidade do modelo esconda problemas de dados.

9. Conclusão

A entrega intermediária mostra avanço substancial além do *baseline* inicial. O projeto passou de uma prova de viabilidade para um experimento mais organizado, com dataset consolidado, protocolo documentado, métricas formais e resultados comparativos.

Ao mesmo tempo, a análise crítica indica que a próxima evolução deve ser guiada por evidências: revisão manual das segmentações, criação de *ground truth* e comparação controlada com modelos semânticos. Assim, o *baseline* atual cumpre seu papel de referência simples e rastreável para as próximas etapas do projeto.