

Auditoria Automática de Trabalhos Acadêmicos: Alinhamento entre Promessas e Entregas com DoCO, TF-IDF e SciBERT

João Pedro Tentis¹

PESC – Universidade Federal do Rio de Janeiro (UFRJ)

Abstract

This paper presents a reproducible pipeline for auditing internal consistency in academic documents. The system extracts text from PDFs, segments rhetorical sections, assigns DoCO-compatible labels, compares introduction promises against delivery sections, and stores the resulting evidence for inspection. The work evolved from a heuristic baseline into an experimental protocol with provisional annotations, two similarity methods, formal ranking and classification metrics, and a SQLite database used by a command-line demonstration. The article reports the method, the experimental design, the observed limitations, and the next steps needed to turn the prototype into a more robust auditing tool.

Resumo

Este artigo apresenta um pipeline reproduzível para auditoria de consistência interna em trabalhos acadêmicos. O sistema extrai texto de PDFs, segmenta seções retóricas, atribui rótulos compatíveis com DoCO, compara promessas da introdução com seções de entrega e armazena as evidências geradas para inspeção. O trabalho evoluiu de um baseline heurístico para um protocolo experimental com anotações provisórias, dois métodos de similaridade, métricas formais de ranking e classificação, e um banco SQLite usado por uma demonstração em linha de comando. O artigo descreve o método, o desenho experimental, as limitações observadas e os próximos passos necessários para tornar o protótipo uma ferramenta de auditoria mais robusta.

1 Links obrigatórios

- GitHub: <https://github.com/jtentis/projeto-BMT>
- Overleaf: <https://tinyurl.com/56nx8f4c>

2 Introdução

Trabalhos acadêmicos criam expectativas antes de apresentar resultados. A introdução declara objetivos, delimita o problema, antecipa contribuições e sugere quais lacunas o texto pretende preencher. Nas seções finais, o leitor espera encontrar uma resposta proporcional a essas promessas. Quando a conclusão extrapola os resultados, quando a seção de resultados não retoma o problema anunciado ou quando o escopo muda sem que a introdução acompanhe essa mudança, o documento perde consistência interna. A identificação desse desalinhamento costuma depender de leitura manual, conhecimento do domínio e atenção à estrutura retórica do texto.

O projeto BMT parte dessa motivação e propõe uma auditoria automática de alinhamento entre promessa e entrega. A proposta inicial definia três tarefas: extrair e segmentar documentos acadêmicos, rotular suas partes com um vocabulário compatível com a Document Components Ontology (DoCO) [2], e comparar os trechos de introdução com seções de resultados, discussão ou conclusão. A primeira entrega executável materializou essa proposta como um baseline offline: o sistema lia PDFs, extraía texto com `pypdf`, detectava cabeçalhos numerados e calculava similaridade TF-IDF com cosseno. As entregas seguintes estabilizaram o experimento: o dataset foi consolidado, as métricas foram formalizadas, os riscos de vazamento foram documentados e o relatório intermediário mostrou que o maior ganho naquele momento não era trocar de modelo, mas tornar o baseline auditável.

Na entrega final, o projeto avança em quatro pontos técnicos. Primeiro, o pipeline passa a exportar rótulos DoCO explícitos para as seções detectadas. Segundo, o experimento incorpora um ground truth provisório para permitir métricas formais de ranking e classificação. Terceiro, o baseline TF-IDF passa a ser comparado com um método baseado em SciBERT [1], modelo pré-treinado para textos científicos. Quarto, os resultados são persistidos em SQLite, permitindo consultas simples durante a demonstração. A contribuição do trabalho não está em substituir revisão humana, mas em produzir uma trilha reproduzível de evidências que

ajude o avaliador a localizar documentos, seções e pares problemáticos.

3 Trabalhos relacionados

A primeira base conceitual do projeto é a representação de componentes documentais. A DoCO define um vocabulário estruturado para descrever partes de documentos, incluindo elementos estruturais e retóricos, como seção, parágrafo, introdução, discussão, figura e apêndice [2]. Esse vocabulário não resolve sozinho a segmentação de PDFs, mas oferece uma forma comum de nomear a função das partes detectadas. No contexto deste projeto, a DoCO atua como camada semântica sobre uma segmentação heurística: o código ainda encontra cabeçalhos por padrões textuais, mas a saída passa a indicar explicitamente papéis como `doco:Introduction`, `doco:Results`, `doco:Discussion`, `doco:Methods` e `doco:Conclusion`.

O problema também se relaciona à classificação de zonas retóricas em artigos científicos. Teufel e Moens [11] mostraram que o papel argumentativo de sentenças pode apoiar tarefas como sumarização científica. Liakata et al. [7] discutem corpora e avaliação para rotulação automática de artigos científicos, destacando que a estrutura retórica exige categorias funcionais e critérios de anotação consistentes. Trabalhos recentes em sumarização de documentos científicos longos também exploram explicitamente estrutura discursiva para ranquear ou separar conteúdos centrais [3, 4]. O presente trabalho não treina um classificador retórico supervisionado, mas herda dessa literatura a ideia de que a posição textual não basta: uma seção deve ser entendida pelo papel que exerce no argumento do documento.

Na dimensão de comparação textual, o baseline usa TF-IDF e similaridade do cosseno. Essa escolha segue uma tradição clássica de recuperação de informação, na qual termos ponderados por frequência local e raridade global formam uma representação vetorial simples e interpretável [8]. Como contraponto, o projeto usa SciBERT, um BERT treinado em corpus científico de larga escala, criado para melhorar tarefas de PLN em textos acadêmicos e técnicos [1]. Para documentos em português, modelos como BERTimbau mostram que pré-treinamento específico para o idioma pode melhorar tarefas de PLN em relação a modelos multilíngues genéricos [10]. A comparação entre os dois métodos testa uma hipótese prática: uma representação contextual densa melhora a auditoria de alinhamento sem fine-tuning ou, neste cenário, a simplicidade lexical continua mais estável?

Por fim, as métricas de avaliação vêm da recuperação de informação e da

classificação. Precision@k e MAP medem qualidade de ranking quando há julgamentos de relevância; NDCG incorpora relevância graduada e desconta posições mais baixas no ranking [5]. Para a tarefa de alinhamento, essas métricas só fazem sentido depois da criação de um ground truth. Por isso as entregas anteriores tratavam Precision@k, MAP, NDCG e F1 como trabalho futuro. A versão final implementa esse elo: cada documento recebe anotações provisórias para os pares introdução-resultados e introdução-conclusão, permitindo avaliar os métodos de forma comparável.

4 Método

4.1 Arquitetura do pipeline

O pipeline executa seis etapas principais. A primeira lê todos os PDFs de `data/raw/` e registra metadados básicos, como nome do documento, número de páginas e status de processamento. A segunda extrai texto com `pypdf`. A terceira normaliza o texto, removendo hifenização artificial, padronizando espaços e criando uma versão sem acentos para busca de cabeçalhos. A quarta etapa identifica títulos numerados ou marcadores textuais próximos de introdução, métodos, resultados, discussão e conclusão. A quinta etapa converte essas seções para rótulos compatíveis com DoCO. A sexta etapa compara a seção de promessa, representada pela introdução, com seções candidatas de entrega. Essa opção por um parser simples contrasta com pipelines recentes baseados em GROBID para extração de bibliografia e metadados científicos [9], mas preserva a transparência necessária à auditoria do protótipo.

Essa arquitetura preserva uma escolha importante feita no baseline: o sistema precisa continuar simples o suficiente para ser reproduzido localmente. A segmentação por cabeçalhos não é o método mais robusto para todos os PDFs, mas permite rastrear erros com facilidade. Cada documento gera texto extraído, texto normalizado, segmentação legada, seções DoCO, resultados de alinhamento e métricas. Assim, quando um score parece estranho, o avaliador consegue voltar ao trecho que originou a comparação. Essa rastreabilidade se mostrou essencial no relatório intermediário, especialmente no caso LCMarques, em que o score zero apontava mais para falha de segmentação do que para ausência comprovada de alinhamento.

4.2 Rotulagem DoCO

A proposta original previa uso do DoCO para representar as partes funcionais do documento. A versão final implementa essa decisão como uma camada explícita de rotulagem. Títulos associados a introdução recebem `doco:Introduction`; títulos associados a resultados, avaliação ou estudo de caso podem receber `doco:Results` ou `doco:Discussion`; títulos de conclusão recebem `doco:Conclusion`. O pipeline também reconhece seções de métodos e trabalhos relacionados quando os cabeçalhos permitem essa inferência. Essa rotulagem não deve ser lida como classificação perfeita: ela é uma aproximação baseada em regras, útil para padronizar a saída e preparar a substituição futura por um classificador retórico supervisionado.

O alinhamento usa a introdução como seção de promessa. As entregas candidatas são resultados, discussão e conclusão, com preservação dos nomes legados `results` e `conclusion` para compatibilidade com relatórios anteriores. Essa decisão reflete a formulação do problema nas entregas iniciais: não se busca medir qualidade científica global, mas verificar se aquilo que o texto promete no início reaparece nas partes em que o trabalho deveria entregar evidência, implementação, análise ou fechamento argumentativo.

4.3 Métodos de similaridade

O primeiro método é o baseline TF-IDF. Para cada par de trechos, o sistema cria vetores com n-gramas de tamanho 1 e 2 e calcula a similaridade do cosseno. O vocabulário é ajustado apenas nos trechos comparados dentro do próprio documento, evitando transferência de estatísticas entre documentos. Quando a segmentação produz trecho vazio ou texto sem vocabulário útil, o score é registrado como 0.0. Essa regra foi necessária após a ampliação do corpus, pois alguns PDFs novos geraram cabeçalhos de sumário como se fossem seções reais.

O segundo método usa SciBERT [1]. O sistema carrega `allenai/scibert_scivocab_uncased`, tokeniza cada trecho, obtém os estados finais dos tokens válidos e calcula a média desses vetores. A similaridade entre promessa e entrega também usa cosseno. Essa implementação não aplica fine-tuning e não ajusta limiares por validação supervisionada. A comparação, portanto, avalia o comportamento de embeddings científicos prontos para uso em uma tarefa de alinhamento textual específica.

4.4 Persistência e demonstração

A entrega final adiciona uma etapa de exportação para SQLite. O banco `reports/final/results.db` contém tabelas para documentos, resultados por método, pares comparados, ground truth, métricas de ranking, métricas de classificação e avaliação por documento. Essa decisão atende a uma exigência prática da entrega: além dos arquivos CSV e JSON, o projeto oferece uma forma simples de consultar resultados com SQL. A demo CLI pode imprimir o resumo do corpus, a comparação entre TF-IDF e SciBERT, as métricas formais e o caso crítico LCMarques diretamente a partir do banco.

5 Dados e protocolo experimental

5.1 Corpus

O corpus atual contém 50 trabalhos acadêmicos em PDF coletados do Pantheon/UFRJ, repositório institucional mantido pelo Sistema de Bibliotecas e Informação da UFRJ. Os arquivos estão versionados em `data/raw/`, permitindo reprodução local sem nova coleta. O uso dos documentos tem finalidade acadêmica, experimental e reprodutível. As orientações do Pantheon indicam que o repositório participa do movimento de acesso aberto, preserva a produção acadêmica da UFRJ e respeita direitos autorais e eventuais embargos definidos pelas comunidades responsáveis.

O pipeline processou todos os 50 documentos sem erro de extração. O conjunto possui 3.595 páginas e 5.867.001 caracteres normalizados. A detecção automática encontrou introdução em 41 documentos, resultados em 40 e conclusão em 36. Esses números mostram uma diferença importante em relação à entrega de dados e métricas, que trabalhava com 10 documentos e cobertura completa das seções. Ao ampliar o corpus, o projeto ganhou diversidade, mas também expôs falhas de segmentação que não apareciam no conjunto menor.

5.2 Ground truth provisório

O arquivo `data/annotations/ground_truth.csv` contém 100 anotações, duas por documento: introdução para resultados e introdução para conclusão. Cada par recebe relevância graduada, com 0 para não relevante, 1 para parcialmente relevante e 2 para relevante. O arquivo também registra o alinhamento esperado em três classes: `aligned`, `partial` e `not_aligned`. As anotações

são provisórias e auditáveis. Elas permitem executar métricas formais, mas ainda não substituem um processo independente com dois avaliadores e medida de concordância.

Essa distinção metodológica importa. Nas entregas anteriores, o projeto evitava reportar F1, MAP ou NDCG porque não havia referência anotada. A versão final só calcula essas métricas depois de ligar os pares comparados a julgamentos de relevância. O ganho é experimental: agora TF-IDF e SciBERT podem ser comparados com a mesma referência. O limite também é claro: a qualidade da avaliação depende da qualidade futura dessas anotações.

5.3 Controle de vazamento

O experimento usa o corpus completo como conjunto fixo de avaliação. Não há divisão entre treino, validação e teste porque nenhum método foi treinado com os rótulos do corpus. O TF-IDF ajusta vocabulário apenas nos dois trechos comparados dentro de cada documento; o SciBERT usa pesos pré-treinados e não recebe fine-tuning; os limiares de rótulo são fixos. Como não há busca de hiperparâmetros guiada pelas métricas finais, o risco de vazamento fica concentrado na curadoria do ground truth e na interpretação dos resultados.

A validação cruzada também não foi usada. Ela faria sentido se o projeto treinasse um classificador ou calibrasse limiares com subconjuntos do corpus. Nesta etapa, a pergunta experimental é mais modesta: dado um corpus fixo, uma segmentação rastreável e duas funções de similaridade, quais pares recebem maior score e como esses scores se comportam contra as anotações disponíveis?

6 Experimentos

6.1 Métricas

Para ranking, o avaliador calcula Precision@1, Precision@2, AP, MAP, NDCG@1 e NDCG@2. Precision@k mede quantos itens relevantes aparecem até a posição k. AP resume a precisão ao longo das posições relevantes de um documento, e MAP calcula a média desses valores. NDCG usa a relevância graduada para premiar métodos que colocam pares mais relevantes no topo do ranking, seguindo a família de métricas proposta por Järvelin e Kekäläinen [5].

Para classificação, os scores são convertidos nos rótulos `aligned`, `partial` e `not_aligned`. O pipeline usa dois limiares: scores maiores ou iguais a 0.35

indicam alinhamento; scores entre 0.15 e 0.35 indicam alinhamento parcial; scores abaixo de 0.15 indicam não alinhamento. O avaliador calcula acurácia, precisão macro, revocação macro, F1 e macro-F1. Esses valores devem ser lidos junto com a natureza provisória do ground truth e com a presença de documentos sem seções suficientes.

6.2 Resultados agregados

Método	P@1	P@2	MAP	NDCG@1	NDCG@2
TF-IDF	0.5200	0.4700	0.5200	0.5200	0.5200
SciBERT	0.5000	0.4700	0.5100	0.4600	0.5004

Table 1: Métricas de ranking no corpus com 50 documentos.

Método	Acurácia	Precisão	Revocação	F1	Macro-F1
TF-IDF	0.9333	0.9015	0.9327	0.9144	0.9144
SciBERT	0.5067	0.5098	0.3571	0.2752	0.2752

Table 2: Métricas de classificação para os pares anotados.

Os resultados de ranking ficaram próximos, com vantagem pequena para TF-IDF. Em classificação, a diferença foi maior: o TF-IDF se ajustou melhor aos limites atuais, enquanto o SciBERT atribuiu scores altos a muitos pares que o ground truth provisório trata como parciais ou não alinhados. Esse comportamento confirma uma hipótese levantada no relatório intermediário: usar uma representação semântica mais forte não resolve, por si só, problemas de segmentação, calibração e definição de relevância.

Table 4: Casos representativos da comparação por documento.

Documento	TF-IDF	Rótulo	SciBERT	Rótulo
AMDDavid	0.4040	high	0.9690	high
BCAbreu	0.4981	high	0.9745	high
GMGonçalves	0.7399	high	0.9451	high

Documento	TF-IDF	Rótulo	SciBERT	Rótulo
LCMarques	0.0000	low	0.6965	high
LFSuett	0.0000	insuff.	0.0000	insuff.
MBSTavares	0.0064	low	0.5668	high
NSahlit	0.0000	low	0.3118	medium
PVMNascimento	0.4224	high	0.9748	high
TAGurgel	0.0612	low	0.6679	high
monopoli10015726	0.0000	low	0.1441	low

7 Discussão

O resultado mais importante não é a vitória de um método sobre outro, mas a separação entre três fontes de erro. A primeira fonte está na extração e segmentação: quando o PDF produz sumário como texto de seção, cabeçalhos duplicados ou trechos vazios, qualquer método de similaridade recebe entrada ruim. A segunda fonte está na representação textual: TF-IDF mede sobreposição lexical e perde casos em que a entrega usa vocabulário diferente da promessa; SciBERT aproxima textos científicos longos de forma ampla e, sem calibração, tende a superestimar alinhamento. A terceira fonte está no próprio ground truth, que ainda é provisório e precisa de revisão independente.

O caso LCMarques mostra como esses erros se combinam. No corpus de 10 documentos, ele já aparecia como o caso crítico, com score TF-IDF igual a 0.0000. No corpus ampliado, o SciBERT atribuiu 0.6965 ao mesmo documento, produzindo leitura oposta. A inspeção dos artefatos indica que a introdução extraída contém ruído de sumário. Assim, o desacordo entre métodos funciona como sinal de auditoria: quando um método lexical vê zero e um embedding contextual vê alto alinhamento, o avaliador deve verificar primeiro a seção comparada, não concluir que um dos métodos “entendeu” melhor o texto.

A ampliação do corpus também muda a interpretação da cobertura. Com 10 PDFs, todos os documentos tinham introdução, resultados e conclusão detectados. Com 50 PDFs, a diversidade editorial aumentou e a cobertura caiu. Isso não invalida o pipeline; pelo contrário, mostra que a avaliação deixou de operar apenas em casos convenientes. A partir desse ponto, melhorar segmentação passa a ser tão importante quanto testar modelos mais sofisticados.




Figure 1: Comparação visual das métricas de ranking entre TF-IDF e SciBERT.

Rótulo TF-IDF	Documentos
high	24
medium	2
low	14
insufficient_sections	10

Table 3: Distribuição dos rótulos de alinhamento no corpus ampliado.

7.1 Ameaças à validade

A validade interna depende da qualidade da segmentação. O pipeline compara seções inteiras, não sentenças anotadas manualmente, e por isso um limite de seção mal posicionado altera o score final. A validade de construto depende da definição de alinhamento: relevância lexical, retomada semântica e consistência argumentativa não são a mesma coisa. O ground truth provisório aproxima esses conceitos para viabilizar avaliação formal, mas ainda precisa de instruções de anotação mais rigorosas e revisão por mais de um avaliador.

A validade externa também tem limites. O corpus cresceu para 50 documentos, mas continua concentrado em uma fonte institucional e em trabalhos acadêmicos com formatos heterogêneos. A generalização para outros repositórios, áreas e estilos editoriais exige nova coleta e nova auditoria. Estudos recentes de parsing de PDF mostram que ferramentas diferentes variam bastante conforme categoria




Figure 2: Distribuição dos rótulos TF-IDF no corpus com 50 documentos.

documental, layout e tipo de conteúdo extraído [6]. Além disso, o SciBERT foi treinado majoritariamente em literatura científica em inglês; seu uso em trabalhos em português pode preservar algumas regularidades científicas, mas não garante representação ideal para o idioma e o domínio local.

8 Conclusão e trabalhos futuros

O projeto entregou um pipeline reproduzível para auditar alinhamento entre promessas e entregas em trabalhos acadêmicos. A trajetória das entregas mostra uma evolução incremental: a proposta definiu o problema e o uso do DoCO; o baseline criou uma execução mínima; a entrega de dados e métricas estabilizou o protocolo; o relatório intermediário identificou limitações concretas; a versão final adicionou ground truth provisório, SciBERT, métricas formais, SQLite e demo. Essa sequência importa porque impediu que a comparação de modelos escondesse problemas básicos de corpus, segmentação e avaliação.

Como próximos passos, o projeto deve revisar manualmente as segmentações dos documentos com `insufficient_sections`, criar anotação independente com medida de concordância, calibrar limiares separadamente para TF-IDF e SciBERT, e testar modelos ajustados ao português acadêmico, como BERTimbau [10]. A substituição gradual da segmentação por cabeçalhos por um classificador retórico supervisionado é o caminho mais promissor. Sem essa melhoria, modelos mais fortes continuarão comparando trechos que nem sempre correspondem às funções retóricas pretendidas.

A Uso de IA

O autor usou Codex/ChatGPT para planejar etapas, revisar texto, apoiar a implementação, estruturar relatórios e conferir comandos de validação. O autor manteve sob responsabilidade humana as decisões de escopo, execução, validação, interpretação dos resultados e submissão. A IA apoiou a organização do ground truth provisório, mas não deve ser tratada como fonte autônoma de verdade experimental. As anotações exigem auditoria humana independente antes de uso como referência definitiva.

References

- [1] Beltagy, I., Lo, K., and Cohan, A. (2019). SciBERT: A Pretrained Language Model for Scientific Text. In *Proceedings of EMNLP-IJCNLP*, pages 3615–3620. <https://arxiv.org/abs/1903.10676>.
- [2] Constantin, A., Peroni, S., Pettifer, S., Shotton, D., and Vitali, F. (2016). The Document Components Ontology (DoCO). *Semantic Web*, 7(2):167–181. <https://www.semantic-web-journal.net/content/document-components-ontology-doco>.
- [3] Dong, Y., Mircea, A., and Cheung, J. C. K. (2021). Discourse-Aware Unsupervised Summarization for Long Scientific Documents. In *Proceedings of the 16th Conference of the European Chapter of the Association for Computational Linguistics*, pages 1089–1102. <https://aclanthology.org/2021.eacl-main.93/>.
- [4] Guo, Y., Ren, X., and Frank, A. (2023). What’s New? Summarizing Contributions in Scientific Literature. In *Proceedings of the 17th Conference of the European Chapter of the Association for Computational Linguistics*, pages 1019–1031. <https://aclanthology.org/2023.eacl-main.72/>.
- [5] Järvelin, K. and Kekäläinen, J. (2002). Cumulated Gain-Based Evaluation of IR Techniques. *ACM Transactions on Information Systems*, 20(4):422–446. <https://doi.org/10.1145/582415.582418>.

- [6] Li, Y., Cao, H., and Luo, Y. (2024). A Comparative Study of PDF Parsing Tools Across Diverse Document Categories. *arXiv preprint arXiv:2410.09871*. <https://arxiv.org/abs/2410.09871>.
- [7] Liakata, M., Teufel, S., Siddharthan, A., and Batchelor, C. R. (2010). Corpora for the Conceptualisation and Zoning of Scientific Papers. In *Proceedings of LREC*.
- [8] Manning, C. D., Raghavan, P., and Schütze, H. (2008). *Introduction to Information Retrieval*. Cambridge University Press. <https://nlp.stanford.edu/IR-book/>.
- [9] Nguyen, T. T. H., Bottoni, P., and Alemu, G. (2023). An End-to-End Pipeline for Bibliography Extraction from Scientific Publications. In *Proceedings of the Second Workshop on Information Extraction from Scientific Publications*, pages 92–103. <https://aclanthology.org/2023.wiesp-1.12/>.
- [10] Souza, F., Nogueira, R., and Lotufo, R. (2020). BERTimbau: Pre-trained BERT Models for Brazilian Portuguese. In *Intelligent Systems*, pages 403–417. Springer. https://doi.org/10.1007/978-3-030-61377-8_28.
- [11] Teufel, S. and Moens, M. (2002). Summarizing Scientific Articles: Experiments with Relevance and Rhetorical Status. *Computational Linguistics*, 28(4):409–445.